AGH w Krakowie · Wydział EAIiIB · Automatyka i Robotyka, II stopień

Optymalizacja wielokryterialna – laboratorium

Sprawozdanie z ćwiczenia 2

Optymalizacja wielokryterialna dyskretna – wyznaczanie zbioru punktów niezdominowanych. Eksperymenty obliczeniowe dla algorytmu naiwnego bez filtracji, z filtracją oraz metody punktu idealnego

Autor: Łukasz Mamczura, Julia Wiater, Kacper Wójcik
Grupa: 2
Prowadzący: dr inż. Przemysław Pukocz
Rok akademicki 2026/2027

1. Cel i zakres ćwiczenia

Celem ćwiczenia była implementacja trzech algorytmów wyznaczania zbioru punktów niezdominowanych P(X) skończonego zbioru $X \subset \mathbb{R}^k$, budowa aplikacji do przeprowadzania eksperymentów obliczeniowych oraz porównanie algorytmów pod względem liczby porównań punktów, liczby porównań współrzędnych i czasu obliczeń.

Zakres wykonanych prac:

- implementacja algorytmów: (1) naiwnego bez filtracji punktów zdominowanych, (2) naiwnego z filtracją, (3) opartego o punkt idealny; algorytmy 1 i 2 dodatkowo w wariancie z sortowaniem wstępnym wg kryterium 1;
- aplikacja z graficznym interfejsem: konfiguracja kryteriów (min/max), generowanie danych z zadanym rozkładem, wczytywanie z pliku, sortowanie, wizualizacja 2D/3D/4D, animacja przebiegu algorytmu, benchmark i serie eksperymentów;
- część A: obliczenia dla zbiorów testowych (przykład z instrukcji oraz zbiór 25-punktowy);
- część B: zbiory losowe – $K_1 = 50$ zbiorów 100-elementowych, $K_2 = 25$ zbiorów 1000-elementowych, $K_3 = 20$ zbiorów 10000-elementowych, $k \in \{2, 3, 4, 5, 10\}$, rozkład jednostajny U[0,2] oraz Gaussa N(1,1) (łącznie 950 zbiorów i 4750 uruchomień algorytmów);
- część 2: zależności regresyjne udziału punktów niezdominowanych od liczby kryteriów ($k_o = 6$ i $k_o = 7$, po 50 zbiorów 100-elementowych).

2. Opis algorytmów

We wszystkich algorytmach kryteria są minimalizowane (kryterium maksymalizowane jest mnożone przez −1). Punkt a dominuje punkt b ($a \le b$), gdy $a_i \le b_i$ dla wszystkich i oraz $a \neq b$.

2.1. Porównanie dwóch punktów

Porównanie punktów a i b przegląda kolejne współrzędne i zapamiętuje, czy wystąpiła współrzędna lepsza dla a i czy wystąpiła współrzędna lepsza dla b. Porównanie kończy się natychmiast, gdy oba zdarzenia zaszły (punkty są nieporównywalne). Jedno wywołanie to jedno porównanie punktów; każde sprawdzenie pary współrzędnych to jedno porównanie współrzędnych. Dla współrzędnych niezależnych o rozkładzie ciągłym oczekiwana liczba porównań współrzędnych w jednym porównaniu punktów wynosi $1 + \Sigma_{j=1}^{k-1} 2^{1-j} = 3 - 2^{2-k}$ (granica 3, zgodnie z analizą w instrukcji).

2.2. Algorytm 1 – naiwny bez filtracji (M1)

Dla kolejnych elementów X(i) pozostałych na liście: Y := X(i), fl := 0; Y jest porównywany z każdym dalszym elementem X(j). Gdy $Y \le X(j)$, X(j) jest usuwany; gdy $X(j) \le Y$, usuwany jest Y, a X(j) staje się nowym Y (fl := 1). Po pętli wewnętrznej Y trafia do P(X); jeżeli fl = 0, Y jest usuwany z przeglądanej listy, w przeciwnym razie pozostaje na niej (bo nie został porównany z elementami leżącymi między X(i) a swoją pozycją). Złożoność pesymistyczna $O(n^2)$ porównań punktów.

2.3. Algorytm 2 – naiwny z filtracją (M2)

Pętla wewnętrzna jak w M1. Po znalezieniu punktu niezdominowanego Y jest on dodawany do P(X), usuwany z listy, a następnie z X usuwane są wszystkie elementy X(k), dla których $Y \le X(k)$ (filtracja). Gdy na liście

zostanie jeden element, jest on niezdominowany. Zgodnie z instrukcją (iteracja 2F) filtracja nie jest wykonywana, gdy jedyny pozostały element był już porównany z Y.

2.4. Algorytm 3 – metoda punktu idealnego (M3)

Wyznaczany jest punkt idealny x_min (minimum każdej współrzędnej w X) oraz kwadraty odległości d(j) = ‖X(j) − x_min‖². Punkty są sortowane rosnąco wg d. Kolejny nieusunięty punkt w tej kolejności jest niezdominowany (gdyby był zdominowany przez y, to d(y) < d(x), więc y byłby wcześniej). Punkt ten trafia do P(X), a z X usuwane są wszystkie punkty, które dominuje. Do sortowania użyto sortowania przez scalanie z licznikiem porównań.

2.5. Sortowanie wstępne (M1S, M2S) i porównywalność metod

W wariantach M1S i M2S zbiór jest wstępnie sortowany (sortowanie przez scalanie, stabilne) rosnąco wg kryterium 1. Porównania w fazie sortowania to porównania pojedynczych liczb (K_1). Zgodnie z odpowiedzią na pytanie 1 z instrukcji przeliczono je na hipotetyczną liczbę porównań punktów: $P_1 = K_1 \cdot P_2/K_2$, gdzie P_2 i K_2 to liczby porównań punktów i współrzędnych w drugiej fazie algorytmu. Raportowana łączna liczba porównań punktów to $P = P_1 + P_2$, a łączna liczba porównań współrzędnych $K = K_1 + K_2$. To samo przeliczenie zastosowano do sortowania odległości w M3.

2.6. Weryfikacja poprawności

Wszystkie warianty sprawdzono automatycznie (skrypt test_owd.py) na 10 080 losowych przypadkach (n od 1 do 300, k od 1 do 5, rozkłady jednostajny, Gaussa, wykładniczy i Poissona – ten ostatni z powtarzającymi się punktami), porównując wynik z przeglądem zupełnym. Wszystkie wyniki były zgodne. W eksperymentach części B dla każdego zbioru sprawdzano, że pięć wariantów zwraca identyczny zbiór P(X), a dla n ≤ 1000 dodatkowo zgodność z przeglądem zupełnym.

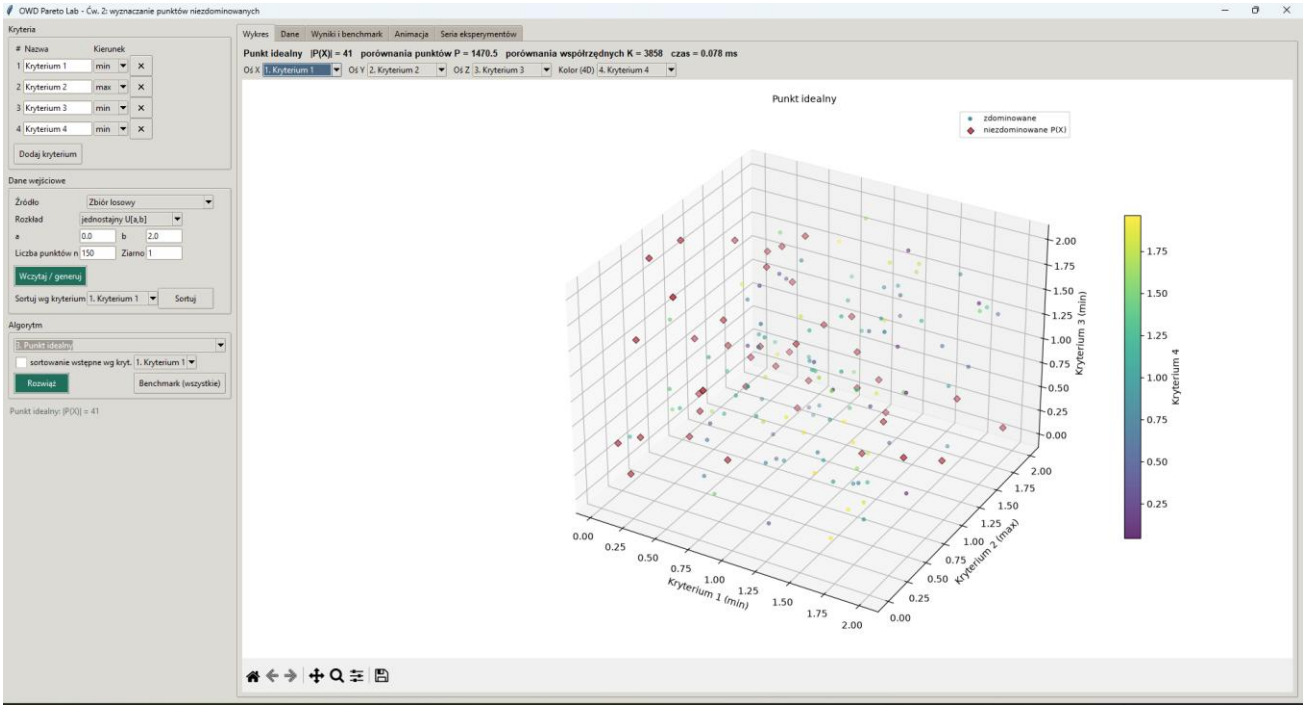
Dla przykładu z instrukcji (12 punktów) liczby porównań są zgodne z tabelami w instrukcji: M1 – 21 porównań punktów (42 współrzędnych), M2 – 16 porównań (32 współrzędnych), wynik P(X) = {(3,3), (1,8), (4,1)}.

3. Aplikacja do eksperymentów obliczeniowych

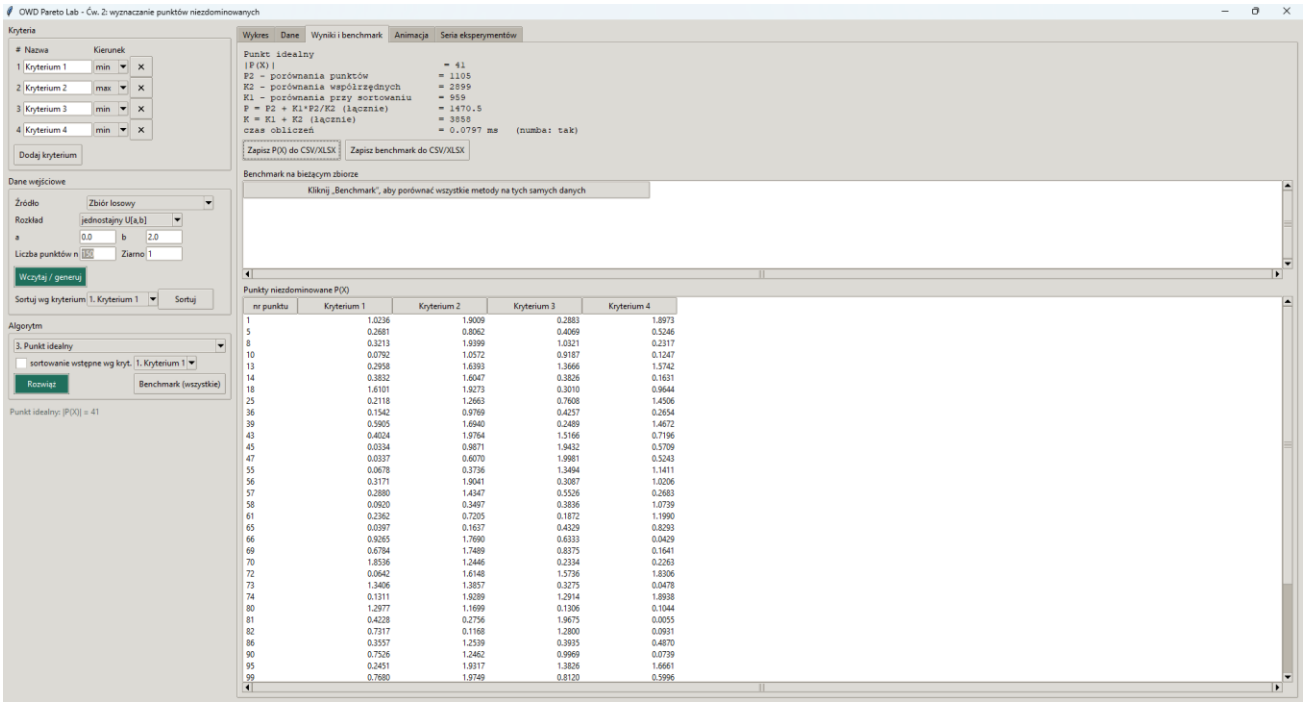
Aplikację „OWD Pareto Lab” napisano w języku Python 3: interfejs graficzny w bibliotece tkinter, wykresy w matplotlib, obliczenia w numpy (plik app.py, uruchomienie: python app.py). Algorytmy znajdują się w module owd.py; pętle algorytmów są kompilowane kompilatorem JIT numba (jeżeli pakiet jest zainstalowany, w przeciwnym razie kod działa w czystym Pythonie, wolniej). Ten sam moduł owd.py jest używany przez skrypt eksperymentów run_experiments.py, dzięki czemu wyniki w aplikacji i w sprawozdaniu pochodzą z tego samego kodu. Moduły aplikacji:

- **Kryteria –** dodawanie, usuwanie i zmiana nazw kryteriów, wybór kierunku (min/max) niezależnie dla każdego kryterium.
- **Dane wejściowe –** generowanie zbioru o zadanej liczności z rozkładu jednostajnego, Gaussa, wykładniczego lub Poissona (parametry i ziarno generatora), zbiory testowe z instrukcji, wczytanie z pliku CSV/TXT/XLSX, sortowanie wg wybranego kryterium, podgląd tabeli danych.
- **Algorytm –** wybór jednej z trzech metod, opcja sortowania wstępnego wg wybranego kryterium, przycisk „Rozwiąż”.

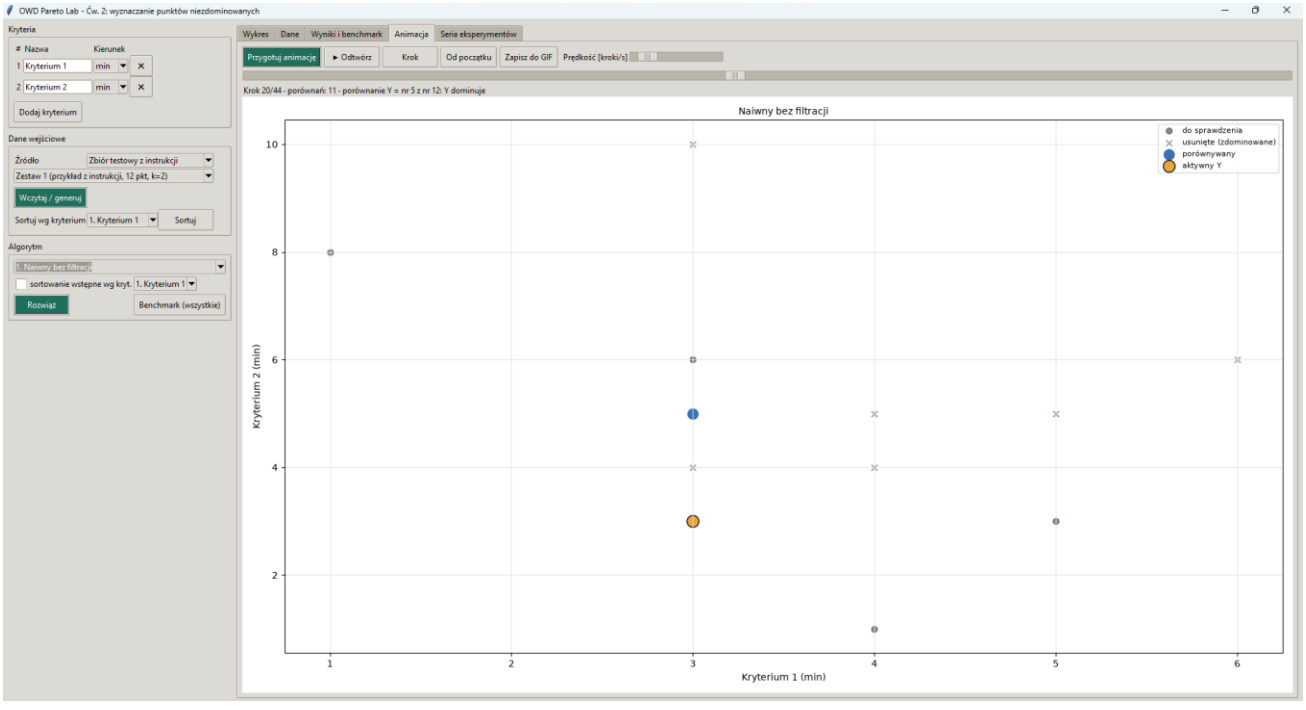
- **Wykres –** wizualizacja zbioru i punktów niezdominowanych w 2D, 3D oraz 4D (czwarte kryterium kodowane kolorem), wybór osi.
- **Wyniki i benchmark –** liczby porównań P_2, K_2, K_1, P, czas; porównanie wszystkich metod na tych samych danych; zapis do CSV lub XLSX.
- **Animacja –** odtwarzanie krok po kroku przebiegu algorytmu (element aktywny Y, porównywany punkt, usunięte punkty, P(X)), zapis animacji do pliku GIF.
- **Seria eksperymentów –** automatyczne wykonanie serii (listy n, k, liczby zbiorów K, rozkład) w osobnym wątku, z paskiem postępu, tabelą średnich ± odchyleń i zapisem do CSV.



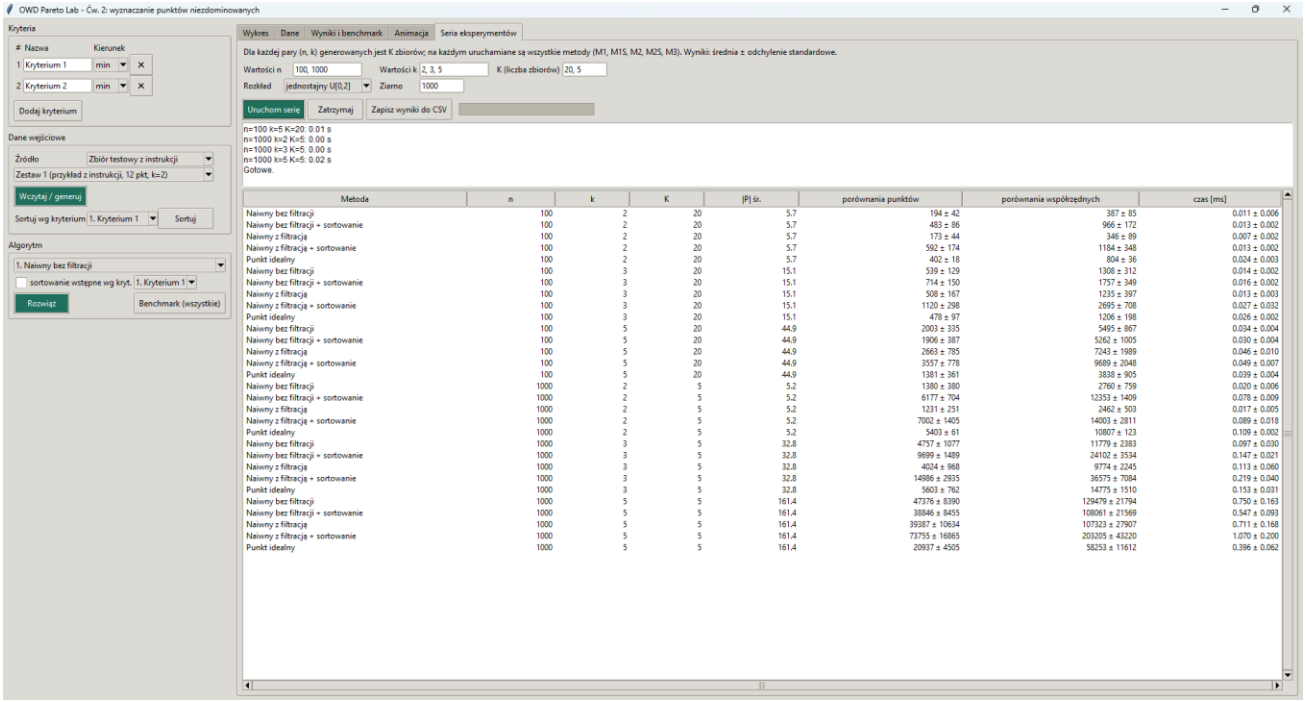
Rys. 1. Aplikacja – wynik metody punktu idealnego dla 150 punktów i 4 kryteriów (kryterium 2 maksymalizowane, kryterium 4 kodowane kolorem).



Rys. 2. Aplikacja – benchmark wszystkich metod na tym samym zbiorze danych.



Rys. 3. Aplikacja – animacja przebiegu algorytmu bez filtracji dla zbioru z instrukcji.



Rys. 4. Aplikacja – seria eksperymentów na zbiorach losowych.

4. Warunki eksperymentów

Tabela 1. Środowisko obliczeniowe.

Parametr	Wartość
Procesor	Intel(R) Xeon(R) Processor @ 2.10GHz, 4 rdzenie (obliczenia jednowątkowe)
Pamięć RAM	15.7 GB
Środowisko	Python 3.12.3, numpy 2.5.4, numba 0.68.1 (kompilacja JIT), Linux-6.18.44-fc-v310-x86_64-with-glibc2.39
Generator liczb losowych	numpy.random.default_rng (PCG64) z ustalonym ziarnem – wyniki powtarzalne
Rozkłady	jednostajny U[0,2] (obowiązkowy) oraz Gaussa N(1,1) (wybrany)
Pomiar czasu	time.perf_counter(); dla n = 100 średnia z 20 powtórzeń, dla n = 1000 z 3 powtórzeń; czas obejmuje sortowanie i wyznaczenie P(X)

5. Wyniki – część A: zbiory testowe

Tabela 2. Wyniki dla zbiorów testowych (zestaw 1: 12 punktów z instrukcji, zestaw 2: 25 punktów, k = 2, oba kryteria minimalizowane).

Zbiór	Metoda	|P|	P_2	K_2	K_1 (sort.)	$P = P_1+P_2$	$K = K_1+K_2$	czas [µs]
Zestaw 1	M1	3	21	42	0	21.0	42	1.56
Zestaw 1	M1S	3	21	42	31	36.5	73	2.33
Zestaw 1	M2	3	16	32	0	16.0	32	1.38
Zestaw 1	M2S	3	30	60	31	45.5	91	2.29
Zestaw 1	M3	3	12	24	30	27.0	54	5.03
Zestaw 2	M1	4	27	54	0	27.0	54	1.38
Zestaw 2	M1S	4	61	122	89	105.5	211	2.67
Zestaw 2	M2	4	32	64	0	32.0	64	1.37
Zestaw 2	M2S	4	101	202	89	145.5	291	3.01
Zestaw 2	M3	4	27	54	93	73.5	147	5.95

Oznaczenia metod: M1 – naiwny bez filtracji, M1S – M1 z sortowaniem wstępnym wg kryterium 1, M2 – naiwny z filtracją, M2S – M2 z sortowaniem wstępnym, M3 – punkt idealny. P_2, K_2 – porównania punktów i współrzędnych w fazie właściwej, K_1 – porównania w fazie sortowania.

Przykład błędnego wyniku (zestaw 1). Jeżeli w algorytmie bez filtracji punkt Y zostanie usunięty z listy po pierwszej iteracji (mimo fl = 1) i pominie się filtrację, otrzymuje się P(X) = {(3,6), (3,3), (1,8), (4,1)}: punkt (3,6) zostaje błędnie uznany za niezdominowany, ponieważ jedynym punktem, który go dominuje, jest usunięty wcześniej punkt (3,3). Jest to dokładnie sytuacja opisana w instrukcji; moduł owd.py odtwarza ją wywołaniem run(X, 'nofilter', wrong=True).

Dla tak małych zbiorów najmniej porównań wykonuje metoda z filtracją (zestaw 1) lub bez filtracji (zestaw 2), a koszt sortowania w M1S, M2S i M3 jest większy niż zysk – sortowanie opłaca się dopiero przy większej liczbie kryteriów i większych zbiorach (część B).

6. Wyniki – część B: zbiory losowe

Tabele 3 i 4 zawierają średnie ± odchylenia standardowe (po K zbiorach) łącznej liczby porównań punktów P, liczby porównań punktów w fazie właściwej P_2, łącznej liczby porównań współrzędnych K oraz czasu obliczeń. Pełne surowe wyniki dla każdego zbioru zawiera plik results/partB_random_raw.csv.

Tabela 3. Wyniki dla zbiorów losowych – rozkład jednostajny U[0,2] (n = 100: K = 50, n = 1000: K = 25, n = 10000: K = 20). Pogrubiono metodę z najmniejszą średnią łączną liczbą porównań punktów.

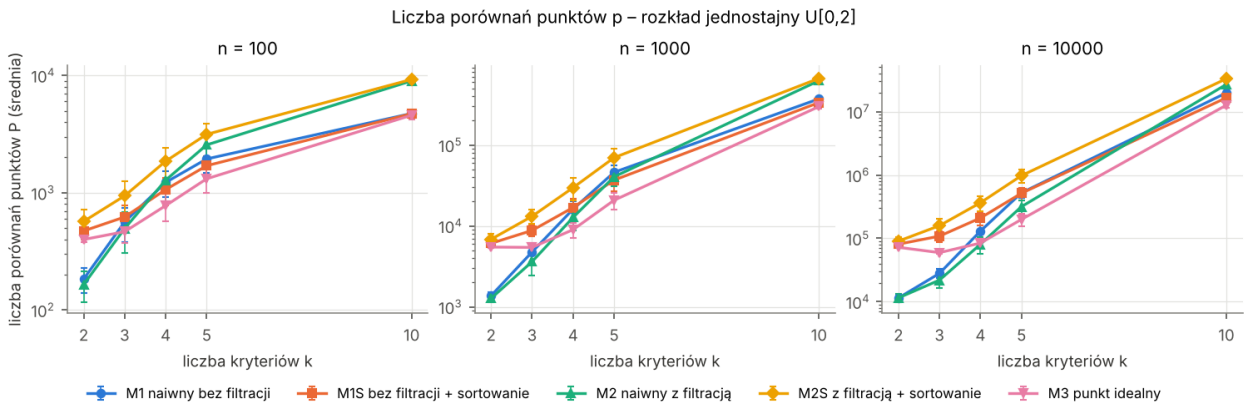
n	k	Metoda	|P| śr.	P (łącznie)	P_2	K (łącznie)	czas [ms]
100	2	M1	5.0	183 ± 44	183 ± 44	367 ± 89	0.003 ± 0.001
100	2	M1S	5.0	472 ± 73	193 ± 73	944 ± 146	0.007 ± 0.005
100	**2**	**M2**	**5.0**	**165 ± 48**	**165 ± 48**	**329 ± 96**	**0.003 ± 0.001**
100	2	M2S	5.0	569 ± 148	290 ± 147	1 138 ± 295	0.007 ± 0.001
100	2	M3	5.0	399 ± 17	120 ± 17	798 ± 35	0.013 ± 0.002
100	3	M1	14.3	564 ± 184	564 ± 184	1 374 ± 430	0.006 ± 0.001
100	3	M1S	14.3	621 ± 158	401 ± 150	1 563 ± 353	0.008 ± 0.001
100	3	M2	14.3	495 ± 187	495 ± 187	1 214 ± 439	0.005 ± 0.001
100	3	M2S	14.3	941 ± 311	716 ± 304	2 311 ± 717	0.010 ± 0.002
100	**3**	**M3**	**14.3**	**465 ± 95**	**250 ± 85**	**1 196 ± 200**	**0.014 ± 0.001**
100	4	M1	28.2	1 224 ± 310	1 224 ± 310	3 276 ± 786	0.011 ± 0.003
100	4	M1S	28.2	1 063 ± 283	861 ± 276	2 912 ± 692	0.012 ± 0.002
100	4	M2	28.2	1 279 ± 448	1 279 ± 448	3 404 ± 1 154	0.012 ± 0.004
100	4	M2S	28.2	1 856 ± 563	1 650 ± 558	4 978 ± 1 407	0.018 ± 0.006
100	**4**	**M3**	**28.2**	**775 ± 209**	**576 ± 201**	**2 153 ± 518**	**0.017 ± 0.002**
100	5	M1	43.4	1 941 ± 456	1 941 ± 456	5 430 ± 1 207	0.019 ± 0.006
100	5	M1S	43.4	1 698 ± 357	1 501 ± 352	4 799 ± 917	0.019 ± 0.004
100	5	M2	43.4	2 557 ± 722	2 557 ± 722	7 031 ± 1 933	0.028 ± 0.010
100	5	M2S	43.4	3 145 ± 714	2 944 ± 710	8 753 ± 1 866	0.033 ± 0.019
100	**5**	**M3**	**43.4**	**1 314 ± 321**	**1 119 ± 316**	**3 714 ± 825**	**0.023 ± 0.004**
100	10	M1	93.8	4 740 ± 133	4 740 ± 133	14 137 ± 649	0.071 ± 0.012
100	10	M1S	93.8	4 723 ± 296	4 536 ± 295	14 093 ± 953	0.055 ± 0.009
100	10	M2	93.8	8 996 ± 669	8 996 ± 669	26 674 ± 2 226	0.134 ± 0.024
100	10	M2S	93.8	9 252 ± 595	9 064 ± 594	27 563 ± 1 942	0.104 ± 0.019
100	**10**	**M3**	**93.8**	**4 583 ± 366**	**4 395 ± 366**	**13 606 ± 1 172**	**0.074 ± 0.014**
1000	2	M1	7.3	1 371 ± 140	1 371 ± 140	2 742 ± 279	0.034 ± 0.006
1000	2	M1S	7.3	6 093 ± 573	1 733 ± 572	12 186 ± 1 147	0.122 ± 0.016
1000	**2**	**M2**	**7.3**	**1 270 ± 128**	**1 270 ± 128**	**2 540 ± 256**	**0.025 ± 0.007**
1000	2	M2S	7.3	6 833 ± 1 147	2 474 ± 1 146	13 667 ± 2 295	0.131 ± 0.025
1000	2	M3	7.3	5 474 ± 85	1 115 ± 86	10 949 ± 171	0.164 ± 0.020
1000	3	M1	29.5	4 759 ± 1 190	4 759 ± 1 190	11 714 ± 2 722	0.114 ± 0.029
1000	3	M1S	29.5	8 787 ± 1 333	5 254 ± 1 274	21 654 ± 2 954	0.191 ± 0.031
1000	**3**	**M2**	**29.5**	**3 611 ± 1 162**	**3 611 ± 1 162**	**9 017 ± 2 674**	**0.096 ± 0.032**
1000	3	M2S	29.5	13 153 ± 2 595	9 537 ± 2 551	31 673 ± 5 921	0.290 ± 0.148
1000	3	M3	29.5	5 427 ± 673	2 125 ± 563	14 289 ± 1 299	0.194 ± 0.026
1000	4	M1	78.2	16 109 ± 4 040	16 109 ± 4 040	42 656 ± 10 147	0.330 ± 0.079
1000	4	M1S	78.2	16 890 ± 4 641	13 687 ± 4 559	45 717 ± 11 394	0.346 ± 0.078
1000	4	M2	78.2	12 726 ± 4 029	12 726 ± 4 029	33 885 ± 10 220	0.327 ± 0.095
1000	4	M2S	78.2	29 712 ± 9 196	26 451 ± 9 128	79 024 ± 22 830	0.610 ± 0.187
1000	**4**	**M3**	**78.2**	**8 985 ± 1 826**	**5 897 ± 1 722**	**25 241 ± 4 387**	**0.305 ± 0.087**
1000	5	M1	160.4	46 026 ± 10 366	46 026 ± 10 366	126 169 ± 26 730	1.125 ± 0.295

1000	5	M1S	160.4	36 862 ± 10 167	33 753 ± 10 118	103 027 ± 27 166	0.809 ± 0.244
1000	5	M2	160.4	40 499 ± 9 621	40 499 ± 9 621	110 718 ± 25 197	1.135 ± 0.325
1000	5	M2S	160.4	69 808 ± 20 295	66 665 ± 20 258	193 132 ± 54 443	1.526 ± 0.491
1000	**5**	**M3**	**160.4**	**20 773 ± 4 984**	**17 678 ± 4 901**	**58 247 ± 12 682**	**0.625 ± 0.158**
1000	10	M1	765.7	372 926 ± 22 345	372 926 ± 22 345	1 112 240 ± 62 311	7.303 ± 0.860
1000	10	M1S	765.7	335 547 ± 20 805	332 613 ± 20 789	996 097 ± 57 448	5.328 ± 0.536
1000	10	M2	765.7	625 329 ± 41 747	625 329 ± 41 747	1 834 090 ± 117 038	12.624 ± 1.156
1000	10	M2S	765.7	667 927 ± 41 618	664 990 ± 41 602	1 981 130 ± 115 133	10.941 ± 1.370
1000	**10**	**M3**	**765.7**	**299 440 ± 19 744**	**296 473 ± 19 729**	**879 471 ± 54 274**	**6.306 ± 0.872**
10000	**2**	**M1**	**10.7**	**11 483 ± 959**	**11 483 ± 959**	**22 966 ± 1 918**	**0.253 ± 0.066**
10000	2	M1S	10.7	81 144 ± 6 885	19 314 ± 6 893	162 287 ± 13 770	1.891 ± 0.311
10000	2	M2	10.7	11 518 ± 1 653	11 518 ± 1 653	23 035 ± 3 307	0.236 ± 0.068
10000	2	M2S	10.7	90 468 ± 13 780	28 638 ± 13 788	180 936 ± 27 560	2.025 ± 0.230
10000	2	M3	10.7	72 278 ± 322	10 456 ± 322	144 555 ± 644	2.143 ± 0.161
10000	3	M1	49.3	28 025 ± 4 611	28 025 ± 4 611	71 853 ± 10 877	1.147 ± 0.184
10000	3	M1S	49.3	108 396 ± 21 683	59 090 ± 20 872	271 204 ± 49 064	2.785 ± 0.440
10000	**3**	**M2**	**49.3**	**21 946 ± 5 705**	**21 946 ± 5 705**	**57 515 ± 13 377**	**0.905 ± 0.215**
10000	3	M2S	49.3	158 532 ± 42 315	108 229 ± 41 748	388 878 ± 98 139	3.978 ± 0.864
10000	3	M3	49.3	59 588 ± 2 765	15 175 ± 1 963	165 832 ± 4 824	2.454 ± 0.128
10000	4	M1	167.3	130 384 ± 29 126	130 384 ± 29 126	349 204 ± 74 112	4.513 ± 0.970
10000	4	M1S	167.3	209 769 ± 50 014	164 280 ± 49 246	568 528 ± 128 919	5.219 ± 1.138
10000	**4**	**M2**	**167.3**	**80 726 ± 22 817**	**80 726 ± 22 817**	**222 703 ± 60 181**	**3.361 ± 1.116**
10000	4	M2S	167.3	364 956 ± 99 046	318 727 ± 98 511	974 058 ± 257 911	9.055 ± 2.245
10000	4	M3	167.3	84 310 ± 14 354	42 289 ± 12 368	246 899 ± 31 539	3.660 ± 0.812
10000	5	M1	426.6	522 639 ± 90 021	522 639 ± 90 021	1 436 680 ± 240 005	15.578 ± 2.551
10000	5	M1S	426.6	515 102 ± 113 318	470 926 ± 112 989	1 439 780 ± 308 500	12.203 ± 2.148
10000	5	M2	426.6	316 165 ± 82 652	316 165 ± 82 652	874 516 ± 224 854	11.074 ± 2.419
10000	5	M2S	426.6	976 836 ± 226 240	932 278 ± 226 012	2 708 050 ± 617 177	23.619 ± 4.487
10000	**5**	**M3**	**426.6**	**199 037 ± 42 492**	**155 842 ± 41 897**	**568 472 ± 116 110**	**7.733 ± 1.349**
10000	10	M1	4973.4	19 776 600 ± 1 567 410	19 776 600 ± 1 567 410	58 527 300 ± 4 354 880	449.847 ± 47.143
10000	10	M1S	4973.4	16 550 000 ± 1 537 430	16 507 800 ± 1 537 340	48 546 600 ± 4 422 300	343.801 ± 47.445
10000	10	M2	4973.4	26 907 300 ± 2 529 450	26 907 300 ± 2 529 450	77 412 000 ± 7 143 340	650.107 ± 66.976
10000	10	M2S	4973.4	33 052 800 ± 3 074 990	33 010 600 ± 3 074 910	96 919 200 ± 8 846 790	678.546 ± 77.237
10000	**10**	**M3**	**4973.4**	**12 672 000 ± 1 174 030**	**12 629 100 ± 1 173 920**	**36 502 600 ± 3 300 760**	**329.398 ± 45.942**

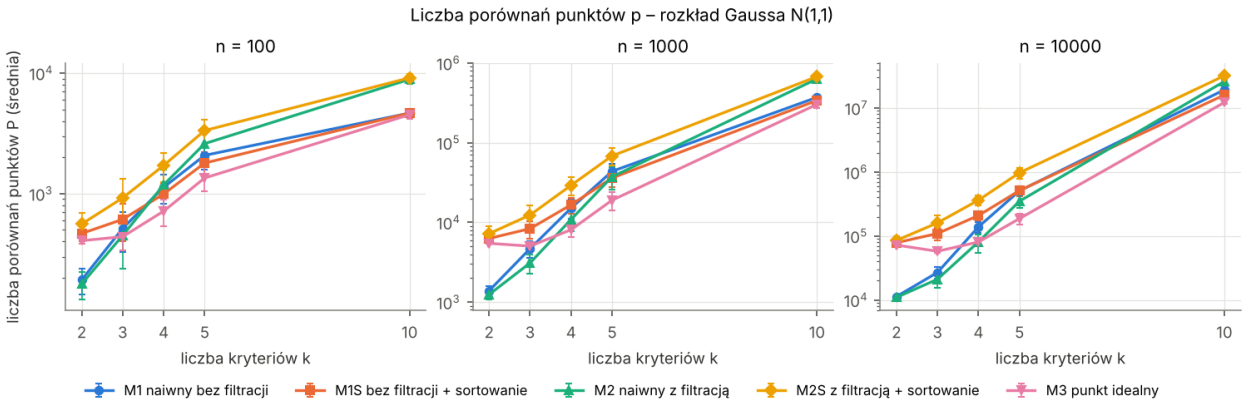
Tabela 4. Wyniki dla zbiorów losowych – rozkład Gaussa N(1,1) (n = 100: K = 50, n = 1000: K = 25, n = 10000: K = 20). Pogrubiono metodę z najmniejszą średnią łączną liczbą porównań punktów.

n	k	Metoda	|P| śr.	P (łącznie)	P_2	K (łącznie)	czas [ms]
100	2	M1	5.4	193 ± 47	193 ± 47	385 ± 95	0.004 ± 0.001
100	2	M1S	5.4	467 ± 64	187 ± 64	934 ± 128	0.008 ± 0.002
100	**2**	**M2**	**5.4**	**178 ± 45**	**178 ± 45**	**356 ± 90**	**0.003 ± 0.001**
100	2	M2S	5.4	559 ± 130	280 ± 130	1 119 ± 260	0.008 ± 0.001
100	2	M3	5.4	407 ± 24	127 ± 23	814 ± 48	0.015 ± 0.002
100	3	M1	13.4	515 ± 189	515 ± 189	1 248 ± 439	0.006 ± 0.002
100	3	M1S	13.4	612 ± 207	391 ± 199	1 530 ± 463	0.009 ± 0.002
100	3	M2	13.4	450 ± 211	450 ± 211	1 096 ± 485	0.006 ± 0.002
100	3	M2S	13.4	921 ± 408	694 ± 401	2 240 ± 935	0.011 ± 0.003
100	**3**	**M3**	**13.4**	**439 ± 101**	**225 ± 89**	**1 139 ± 202**	**0.015 ± 0.002**
100	4	M1	26.4	1 129 ± 303	1 129 ± 303	3 013 ± 792	0.011 ± 0.003
100	4	M1S	26.4	993 ± 233	790 ± 229	2 718 ± 592	0.011 ± 0.002
100	4	M2	26.4	1 183 ± 407	1 183 ± 407	3 133 ± 1 059	0.012 ± 0.004
100	4	M2S	26.4	1 714 ± 465	1 505 ± 462	4 582 ± 1 203	0.017 ± 0.005
100	**4**	**M3**	**26.4**	**715 ± 180**	**516 ± 173**	**1 991 ± 454**	**0.019 ± 0.010**
100	5	M1	44.4	2 077 ± 484	2 077 ± 484	5 763 ± 1 228	0.021 ± 0.006
100	5	M1S	44.4	1 793 ± 398	1 597 ± 393	5 064 ± 1 029	0.020 ± 0.004
100	5	M2	44.4	2 599 ± 695	2 599 ± 695	7 112 ± 1 776	0.029 ± 0.010
100	5	M2S	44.4	3 336 ± 797	3 137 ± 793	9 290 ± 2 087	0.034 ± 0.009
100	**5**	**M3**	**44.4**	**1 349 ± 306**	**1 152 ± 299**	**3 782 ± 764**	**0.025 ± 0.004**
100	10	M1	93.2	4 657 ± 238	4 657 ± 238	13 880 ± 718	0.073 ± 0.012
100	10	M1S	93.2	4 664 ± 340	4 476 ± 338	13 900 ± 975	0.059 ± 0.012
100	10	M2	93.2	8 880 ± 693	8 880 ± 693	26 288 ± 2 144	0.145 ± 0.031
100	10	M2S	93.2	9 132 ± 681	8 944 ± 679	27 171 ± 1 987	0.113 ± 0.023
100	**10**	**M3**	**93.2**	**4 518 ± 362**	**4 328 ± 361**	**13 382 ± 1 048**	**0.081 ± 0.018**
1000	2	M1	7.2	1 387 ± 182	1 387 ± 182	2 774 ± 364	0.029 ± 0.007
1000	2	M1S	7.2	6 286 ± 847	1 927 ± 845	12 573 ± 1 693	0.111 ± 0.017
1000	**2**	**M2**	**7.2**	**1 245 ± 163**	**1 245 ± 163**	**2 490 ± 327**	**0.021 ± 0.008**
1000	2	M2S	7.2	7 220 ± 1 694	2 862 ± 1 693	14 441 ± 3 388	0.117 ± 0.023
1000	2	M3	7.2	5 465 ± 92	1 102 ± 93	10 929 ± 184	0.141 ± 0.015
1000	3	M1	26.8	4 681 ± 1 123	4 681 ± 1 123	11 556 ± 2 735	0.120 ± 0.025
1000	3	M1S	26.8	8 347 ± 2 100	4 919 ± 1 988	21 093 ± 4 553	0.204 ± 0.039
1000	**3**	**M2**	**26.8**	**3 099 ± 836**	**3 099 ± 836**	**7 902 ± 2 035**	**0.090 ± 0.025**
1000	3	M2S	26.8	12 370 ± 4 072	8 864 ± 3 979	30 546 ± 9 116	0.279 ± 0.066

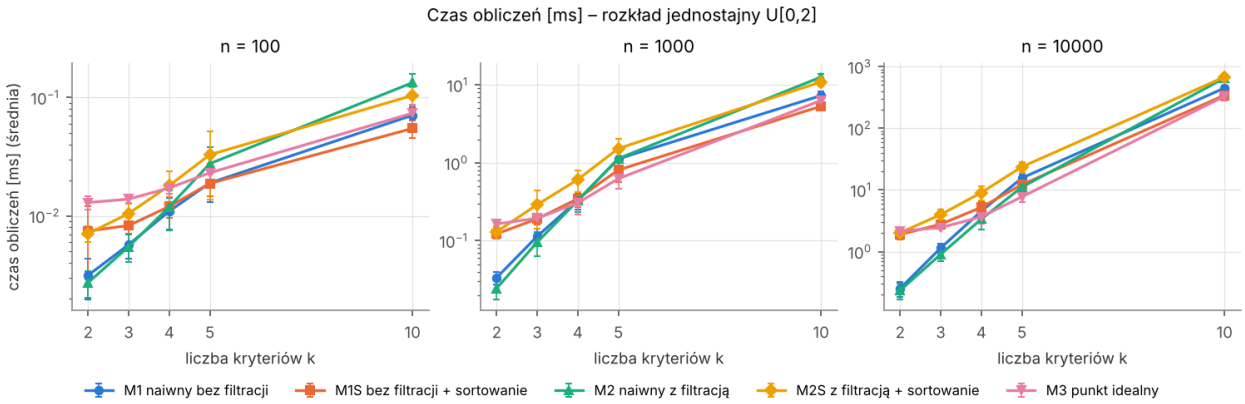
1000	3	M3	26.8	5 037 ± 470	1 808 ± 361	13 584 ± 832	0.203 ± 0.026
1000	4	M1	74.6	15 098 ± 4 075	15 098 ± 4 075	39 948 ± 10 285	0.271 ± 0.070
1000	4	M1S	74.6	16 614 ± 3 749	13 415 ± 3 683	45 129 ± 9 612	0.298 ± 0.070
1000	4	M2	74.6	10 872 ± 3 123	10 872 ± 3 123	29 052 ± 8 091	0.248 ± 0.072
1000	4	M2S	74.6	29 162 ± 7 423	25 904 ± 7 375	77 834 ± 19 266	0.520 ± 0.144
1000	**4**	**M3**	**74.6**	**8 093 ± 1 550**	**5 044 ± 1 472**	**23 095 ± 3 906**	**0.240 ± 0.042**
1000	5	M1	156.2	43 693 ± 10 873	43 693 ± 10 873	120 411 ± 29 393	0.876 ± 0.280
1000	5	M1S	156.2	36 070 ± 8 505	32 986 ± 8 471	101 773 ± 22 946	0.658 ± 0.166
1000	5	M2	156.2	37 334 ± 11 535	37 334 ± 11 535	102 388 ± 30 708	0.902 ± 0.336
1000	5	M2S	156.2	68 245 ± 16 989	65 128 ± 16 962	190 609 ± 45 981	1.294 ± 0.389
1000	**5**	**M3**	**156.2**	**18 979 ± 4 808**	**15 885 ± 4 761**	**53 346 ± 12 748**	**0.500 ± 0.141**
1000	10	M1	769.2	370 463 ± 23 939	370 463 ± 23 939	1 094 860 ± 68 236	6.340 ± 0.914
1000	10	M1S	769.2	338 761 ± 25 583	335 802 ± 25 576	998 927 ± 73 920	4.630 ± 0.594
1000	10	M2	769.2	631 843 ± 60 637	631 843 ± 60 637	1 838 410 ± 177 713	11.004 ± 1.696
1000	10	M2S	769.2	674 334 ± 51 194	671 372 ± 51 187	1 986 820 ± 148 194	9.338 ± 1.142
1000	**10**	**M3**	**769.2**	**302 381 ± 28 553**	**299 385 ± 28 552**	**880 245 ± 83 200**	**5.277 ± 0.665**
10000	2	M1	8.6	11 301 ± 603	11 301 ± 603	22 602 ± 1 205	0.170 ± 0.032
10000	2	M1S	8.6	78 518 ± 6 845	16 685 ± 6 846	157 037 ± 13 690	1.319 ± 0.121
10000	**2**	**M2**	**8.6**	**10 978 ± 768**	**10 978 ± 768**	**21 956 ± 1 537**	**0.139 ± 0.035**
10000	2	M2S	8.6	85 212 ± 13 692	23 378 ± 13 693	170 423 ± 27 384	1.420 ± 0.181
10000	2	M3	8.6	72 080 ± 198	10 246 ± 187	144 161 ± 395	1.515 ± 0.026
10000	3	M1	47.9	26 896 ± 5 450	26 896 ± 5 450	69 072 ± 12 713	0.841 ± 0.155
10000	3	M1S	47.9	109 220 ± 24 844	59 782 ± 23 159	271 648 ± 53 440	2.089 ± 0.322
10000	**3**	**M2**	**47.9**	**21 087 ± 5 602**	**21 087 ± 5 602**	**55 924 ± 13 385**	**0.652 ± 0.173**
10000	3	M2S	47.9	160 079 ± 47 726	109 610 ± 46 322	389 783 ± 106 902	2.966 ± 0.614
10000	3	M3	47.9	57 677 ± 3 320	13 772 ± 2 000	162 372 ± 4 466	1.833 ± 0.096
10000	4	M1	173.6	138 610 ± 26 939	138 610 ± 26 939	370 570 ± 68 657	3.979 ± 0.610
10000	4	M1S	173.6	208 488 ± 31 997	162 996 ± 32 076	567 217 ± 89 918	4.333 ± 0.618
10000	4	M2	173.6	80 608 ± 25 416	80 608 ± 25 416	221 780 ± 66 018	2.756 ± 0.657
10000	4	M2S	173.6	362 364 ± 63 927	316 164 ± 64 168	971 456 ± 179 883	7.594 ± 1.264
10000	**4**	**M3**	**173.6**	**80 415 ± 10 044**	**38 697 ± 8 969**	**237 940 ± 23 998**	**2.919 ± 0.279**
10000	5	M1	443.4	506 403 ± 86 148	506 403 ± 86 148	1 398 480 ± 228 770	12.590 ± 1.896
10000	5	M1S	443.4	511 223 ± 91 610	467 303 ± 91 236	1 437 590 ± 246 339	10.286 ± 1.634
10000	5	M2	443.4	348 688 ± 75 247	348 688 ± 75 247	963 143 ± 197 151	10.067 ± 1.883
10000	5	M2S	443.4	969 335 ± 182 819	925 048 ± 182 511	2 703 740 ± 492 892	19.889 ± 3.374
10000	**5**	**M3**	**443.4**	**186 616 ± 34 481**	**143 600 ± 33 548**	**534 788 ± 88 074**	**6.217 ± 0.883**
10000	10	M1	4892.9	19 210 000 ± 1 173 720	19 210 000 ± 1 173 720	56 859 200 ± 3 299 580	442.196 ± 52.897
10000	10	M1S	4892.9	15 942 100 ± 982 636	15 899 900 ± 982 562	46 757 700 ± 2 806 300	318.737 ± 35.620
10000	10	M2	4892.9	25 957 500 ± 1 699 160	25 957 500 ± 1 699 160	74 573 400 ± 4 852 190	635.061 ± 53.107
10000	10	M2S	4892.9	31 836 900 ± 1 965 340	31 794 700 ± 1 965 270	93 340 600 ± 5 614 070	635.609 ± 63.892
10000	**10**	**M3**	**4892.9**	**12 189 400 ± 771 241**	**12 146 300 ± 771 232**	**35 043 200 ± 2 212 620**	**306.318 ± 36.413**



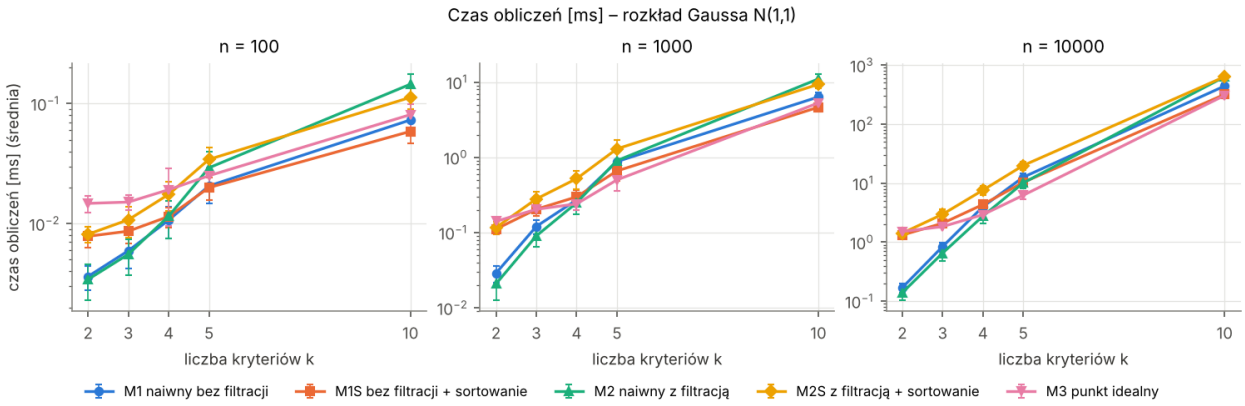
Rys. 5. Łączna liczba porównań punktów P w funkcji liczby kryteriów, rozkład jednostajny (skala logarytmiczna, słupki: ± odchylenie standardowe).



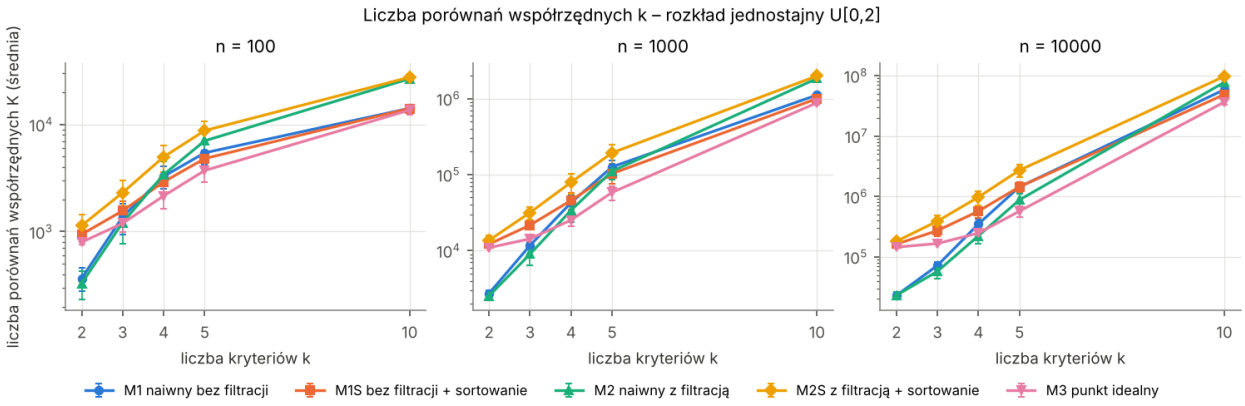
Rys. 6. Łączna liczba porównań punktów P w funkcji liczby kryteriów, rozkład Gaussa.



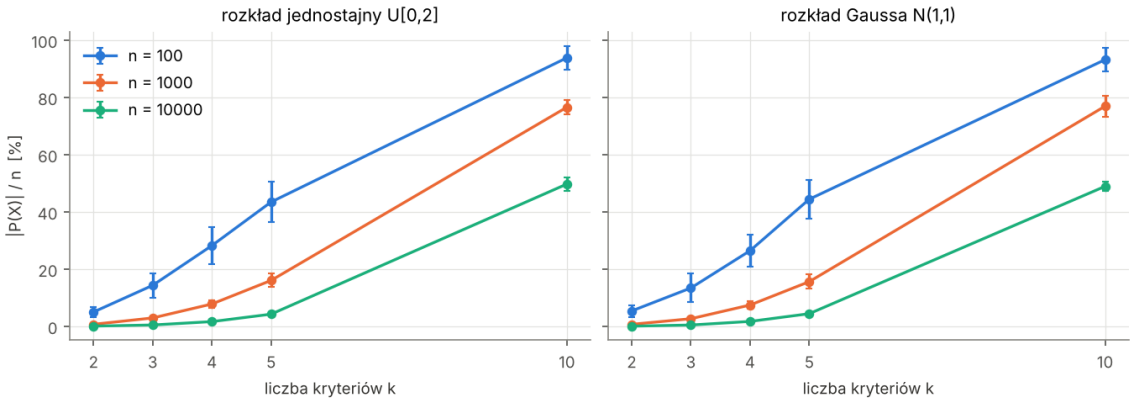
Rys. 7. Czas obliczeń w funkcji liczby kryteriów, rozkład jednostajny.



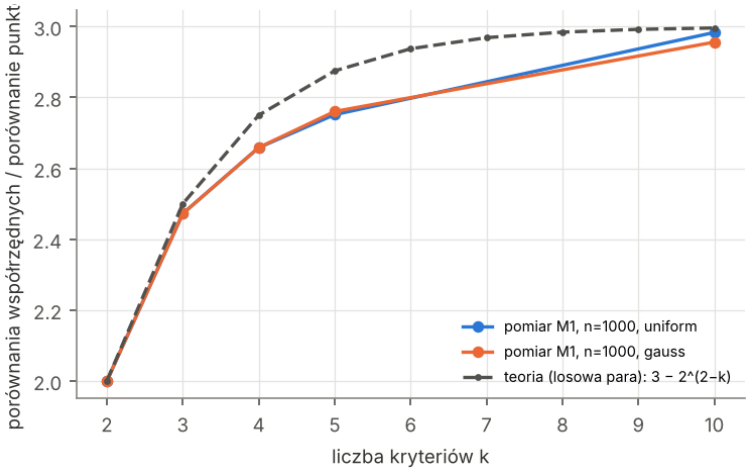
Rys. 8. Czas obliczeń w funkcji liczby kryteriów, rozkład Gaussa.



Rys. 9. Łączna liczba porównań współrzędnych K, rozkład jednostajny.



Rys. 10. Udział punktów niezdominowanych |P(X)|/n w zależności od k i n.



Rys. 11. Średnia liczba porównań współrzędnych przypadająca na jedno porównanie punktów (M1, n = 1000) na tle wartości teoretycznej.

Tabela 5. Łączna liczba porównań punktów względem metody M1 (= 100%) dla n = 10000.

Rozkład	k	M1	M1S	M2	M2S	M3
Gaussa	2	100%	695%	97%	754%	638%
Gaussa	3	100%	406%	78%	595%	214%
Gaussa	4	100%	150%	58%	261%	58%
Gaussa	5	100%	101%	69%	191%	37%

Gaussa	10	100%	83%	135%	166%	64%
jednostajny	2	100%	707%	100%	788%	629%
jednostajny	3	100%	387%	78%	566%	213%
jednostajny	4	100%	161%	62%	280%	65%
jednostajny	5	100%	99%	60%	187%	38%
jednostajny	10	100%	84%	136%	167%	64%

7. Wyniki – część 2: zależności regresyjne

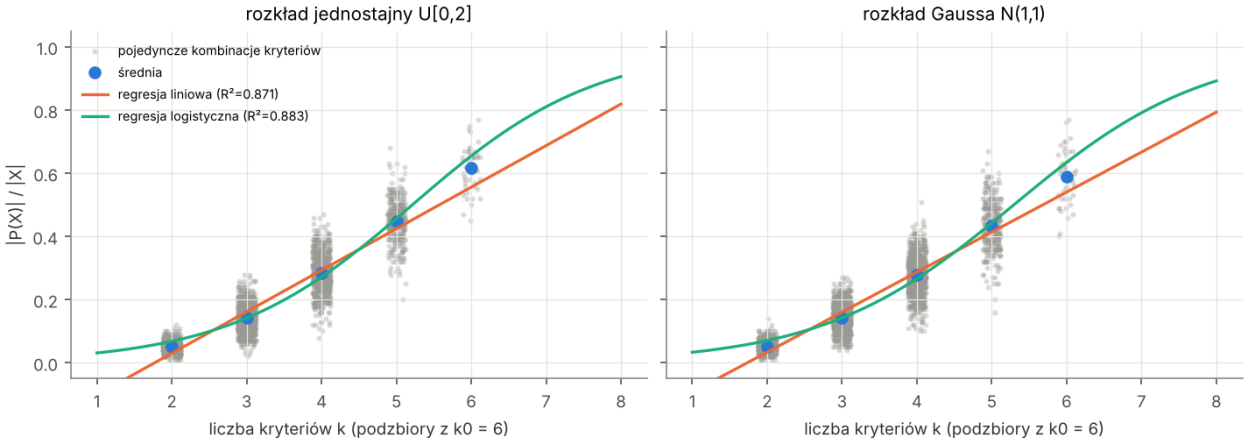
(A) Dla 50 zbiorów 100-elementowych z $k_o = 6$ kryteriami wyznaczono P(X) dla wszystkich C(6,k) kombinacji k kryteriów, k = 2, …, 6 (57 problemów na zbiór, 2850 obserwacji na rozkład) i zbadano zależność ilorazu |P(X)|/|X| od k. (B) Dla 50 zbiorów 100-elementowych z $k_o = 7$ kryteriami wyznaczono iloraz $|P_k(X)|/|P_{k_o}(X)|$ dla wszystkich kombinacji k < 7 kryteriów (126 problemów na zbiór, 6300 obserwacji na rozkład) w funkcji różnicy $k_o - k$. Do wyznaczania P(X) użyto metody punktu idealnego.

Tabela 6. Wyniki regresji.

Zadanie / rozkład	Model	Współczynniki	R^2	istotność b
(A) jednostajny	liniowy: y = a + b·k	a = -0.2326, b = 0.1315 (SE 0.0009)	0.871	$p < 10^{-100}$
(A) jednostajny	logistyczny: y = 1/(1+e^−(a+b·k))	a = -4.238, b = 0.813	0.883	–
(A) Gaussa	liniowy: y = a + b·k	a = -0.2194, b = 0.1266 (SE 0.0010)	0.854	$p < 10^{-100}$
(A) Gaussa	logistyczny: y = 1/(1+e^−(a+b·k))	a = -4.140, b = 0.782	0.860	–
(B) jednostajny	liniowy: y = a + b·(k_o−k)	a = 0.9204, b = -0.1716 (SE 0.0008)	0.881	$p < 10^{-100}$
(B) jednostajny	wykładniczy: y = e^(−c·(k_o−k))	c = 0.3510	0.798	–
(B) Gaussa	liniowy: y = a + b·(k_o−k)	a = 0.9158, b = -0.1702 (SE 0.0008)	0.869	$p < 10^{-100}$
(B) Gaussa	wykładniczy: y = e^(−c·(k_o−k))	c = 0.3506	0.790	–

Tabela 7. Część 2A – średni udział punktów niezdominowanych w zależności od k ($k_o = 6$, n = 100).

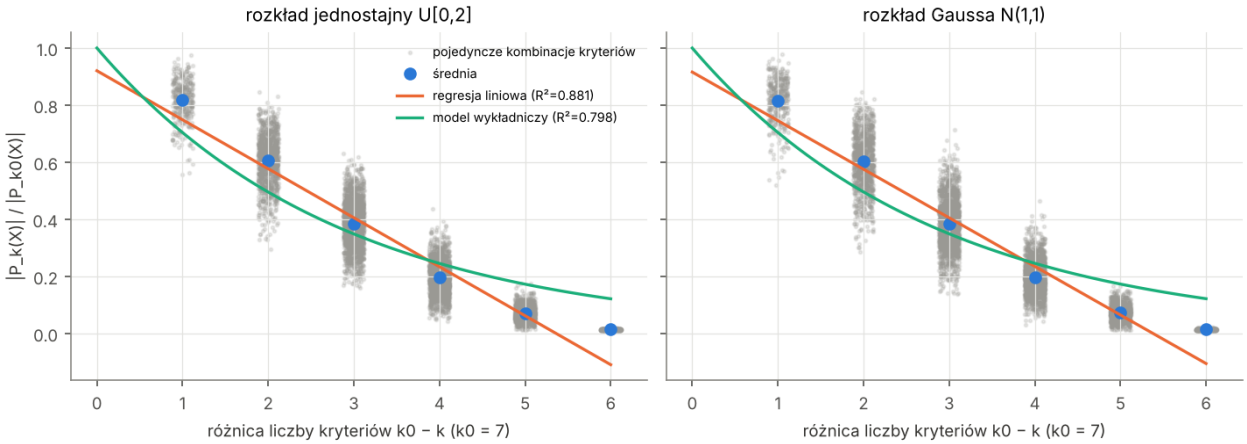
Rozkład	k	|P|/|X| (średnia ± odch.)	liczba obserwacji
jednostajny	2	0.052 ± 0.018	750
jednostajny	3	0.143 ± 0.041	1000
jednostajny	4	0.283 ± 0.061	750
jednostajny	5	0.449 ± 0.071	300
jednostajny	6	0.617 ± 0.069	50
Gaussa	2	0.052 ± 0.018	750
Gaussa	3	0.144 ± 0.042	1000
Gaussa	4	0.279 ± 0.064	750
Gaussa	5	0.435 ± 0.080	300
Gaussa	6	0.588 ± 0.083	50



Rys. 12. Część 2A – udział punktów niezdominowanych w zbiorze 100 punktów w zależności od liczby kryteriów; regresja liniowa i logistyczna.

Tabela 8. Część 2B – iloraz liczby punktów niezdominowanych dla k i k_o = 7 kryteriów.

Rozkład	$k_o - k$	$\|P_k\|/\|P_{k_o}\|$ (średnia ± odch.)	liczba obserwacji
jednostajny	1	0.819 ± 0.070	350
jednostajny	2	0.605 ± 0.089	1050
jednostajny	3	0.384 ± 0.082	1750
jednostajny	4	0.195 ± 0.058	1750
jednostajny	5	0.070 ± 0.026	1050
jednostajny	6	0.014 ± 0.001	350
Gaussa	1	0.816 ± 0.079	350
Gaussa	2	0.602 ± 0.097	1050
Gaussa	3	0.384 ± 0.088	1750
Gaussa	4	0.198 ± 0.059	1750
Gaussa	5	0.073 ± 0.028	1050
Gaussa	6	0.014 ± 0.002	350



Rys. 13. Część 2B – iloraz $|P_k(X)|/|P_{k_o}(X)|$ w funkcji różnicy liczby kryteriów $k_o - k$ (k_o = 7).

8. Wnioski

1. **Poprawność.** Wszystkie trzy algorytmy (oraz warianty z sortowaniem wstępnym) zwracały identyczne zbiory P(X), zgodne z przeglądem zupełnym. Usunięcie punktu Y bez filtracji w algorytmie naiwnym prowadzi do błędnego wyniku – flaga fl (algorytm 1) albo filtracja (algorytm 2) są niezbędne.
2. **Liczba punktów niezdominowanych rośnie gwałtownie z liczbą kryteriów.** Dla k = 2 średnio |P| ≈ 5,0, 7,3 i 10,7 dla n = 100, 1000, 10000, co odpowiada teoretycznej wartości oczekiwanej $H_n = 1 + 1/2 + \ldots + 1/n \approx \ln n + 0{,}577$ (5,19; 7,49; 9,79). Dla k = 10 niezdominowanych jest ok. 94% punktów przy n = 100 i ok. 50% przy n = 10000. Ponieważ koszt wszystkich metod jest proporcjonalny w przybliżeniu do $n \cdot |P(X)|$, liczba kryteriów jest głównym czynnikiem decydującym o czasie obliczeń.
3. **Metoda punktu idealnego (M3) jest najlepsza dla k ≥ 5, a dla k = 4 przy n ≤ 1000.** Dla n = 10000 wykonuje ona 65%, 38% i 64% porównań metody M1 dla k = 4, 5, 10 (rozkład jednostajny; dla k = 4 i n = 10000 nieco mniej porównań wykonuje M2 – 62%). Dla n = 10000 i k ≥ 5 jest też najszybsza (np. k = 10: 329 ms wobec 450 ms dla M1 i 650 ms dla M2); dla małych zbiorów czasy są rzędu setnych części milisekundy i decyduje o nich stały narzut (wywołania numpy, obliczenie odległości), więc tam najszybsze są metody naiwne. Kolejność wg odległości od punktu idealnego gwarantuje, że każdy rozpatrywany punkt jest od razu niezdominowany, więc nie ma porównań „zmarnowanych” na punkty,

które później zostaną usunięte, a punkty bliskie punktu idealnego dominują dużą część zbioru i usuwają ją wcześnie.

4. **Dla małej liczby kryteriów (k = 2, 3) najlepsze są metody naiwne bez sortowania (zwłaszcza M2).** Liczba porównań punktów w M1 i M2 dla k = 2 wynosi tylko ok. 1,1·n (np. 11518 dla n = 10000), ponieważ element aktywny Y szybko „wspina się" do punktu, który dominuje prawie cały zbiór. Koszt sortowania (ok. $n \cdot \log_2 n$ porównań liczb) jest wtedy wielokrotnie większy od kosztu właściwej fazy, dlatego M3 wykonuje dla k = 2 ok. 6,3 razy więcej porównań niż M1, choć w samej fazie właściwej (P_2) jest najoszczędniejsza.
5. **Filtracja (M2) pomaga, gdy punktów niezdominowanych jest mało, a szkodzi, gdy jest ich dużo.** Dla k = 3–5 i n = 10000 M2 wykonuje 60–78% porównań M1, natomiast dla k = 10 aż 136%: przy $|P| \approx 0{,}5 \cdot n$ filtracja prawie niczego nie usuwa, a powtarza porównania z elementami, które były już porównane z Y w pętli wewnętrznej. Ograniczenie filtracji do elementów leżących przed pozycją ostatecznego Y usunęłoby tę nadmiarowość.
6. **Sortowanie wstępne wg jednego kryterium nie poprawia znacząco metod naiwnych.** M1S jest wyraźnie lepszy od M1 tylko dla dużej liczby kryteriów (k = 10: 84% porównań M1; dla k = 4–5 wynik zależy od n, a dla k ≤ 3 sortowanie się nie opłaca), a M2S jest najgorszy we wszystkich przypadkach losowych. Punkt minimalny wg kryterium 1 jest wprawdzie niezdominowany, ale przy k ≥ 3 zwykle słabo wypada w pozostałych kryteriach i dominuje mało punktów, więc nie redukuje zbioru tak skutecznie jak „wspinający się" element aktywny w kolejności losowej. Sortowanie wg odległości od punktu idealnego (M3) uwzględnia wszystkie kryteria jednocześnie i dlatego jest skuteczne.
7. **Liczba porównań współrzędnych jest proporcjonalna do liczby porównań punktów.** Średnia liczba porównań współrzędnych na jedno porównanie punktów wynosi 2,0 dla k = 2 i rośnie do ok. 2,9–3,0 dla k = 10, zgodnie z wartością teoretyczną $3 - 2^{2-k}$ dla losowej pary. Dzięki wczesnemu przerywaniu porównania koszt porównania punktów praktycznie nie zależy od k, a liczba porównań punktów jest dobrą miarą do porównywania algorytmów; czas obliczeń jest z nią silnie skorelowany.
8. **Rozkład danych (jednostajny vs Gaussa) praktycznie nie wpływa na wyniki.** Różnice mieszczą się w granicach rozrzutu losowego. Wynika to z faktu, że relacja dominacji zależy tylko od uporządkowania wartości w każdej współrzędnej, a dla niezależnych współrzędnych o tym samym rozkładzie ciągłym rozkład tych uporządkowań jest taki sam niezależnie od rozkładu. Inaczej byłoby dla rozkładów dyskretnych (np. Poissona), gdzie pojawiają się równe współrzędne i punkty.
9. **Zależność udziału punktów niezdominowanych od liczby kryteriów jest nieliniowa.** W części 2A regresja logistyczna ($R^2 = 0{,}883$) opisuje dane lepiej niż liniowa ($R^2 = 0{,}871$); model liniowy daje ujemny udział dla k = 1 i udział powyżej 100% dla dużych k, czego model logistyczny nie robi – potwierdza to uwagę z instrukcji, że prawidłowym modelem jest regresja logistyczna. W części 2B każde usunięte kryterium zmniejsza liczbę punktów niezdominowanych średnio o ok. 17 punktów procentowych liczby $|P_k_o|$ ($R^2 = 0{,}881$); dla $k_o - k = 1$ zostaje ok. 82% punktów, a dla k = 1 – jeden punkt.
10. **Rekomendacja.** Dla k ≤ 3 należy stosować algorytm naiwny (najlepiej z filtracją) bez sortowania; dla k ≥ 4 – metodę punktu idealnego, której przewaga rośnie wraz z liczbą kryteriów i licznością zbioru.

Załączniki

- **app.py –** aplikacja z interfejsem graficznym (python app.py)
- **owd.py –** moduł z algorytmami
- **test_owd.py –** testy poprawności (python test_owd.py)

- **run_experiments.py –** pełna seria eksperymentów (python run_experiments.py)
- **analyze.py, build_report.py –** opracowanie wyników (tabele, wykresy, regresje) i generowanie sprawozdania
- **results/*.csv –** surowe i zagregowane wyniki eksperymentów
- **results/figures/*.png –** wykresy i zrzuty ekranu aplikacji